

# Alineamientos de secuencias (Pairwise alignments)

BCH441 - Bioinformatics  
Boris Steipe

[http://steipe.biochemistry.utoronto.ca/abc/index.php/Bioinformatics\\_Main\\_Page](http://steipe.biochemistry.utoronto.ca/abc/index.php/Bioinformatics_Main_Page)

<http://circos.ca/>

# Buenas prácticas en Bioinformatics

---

¿Cómo llevan a diario el seguimiento de sus experimentos de wet-lab?

¿Qué prácticas tienen regularmente en el laboratorio?

¿Cómo hacer esto en análisis bioinformáticos?

Necesitamos saber el tipo de sistema operativo que utilizan  
(Linux/Windows/macOS/otro)

# Alineamiento de secuencias

## ¿Qué es una secuencia?

Una secuencia tiene: composición; largo; dirección; orden..

Un gen, un transcripto, una  
proteína, un fragmento de una de  
las anteriores, una estructura, una  
función

DNA

CAAGTTGGAT**YNN**TAC

RNA

AUGCAUC**R**CGC**N**UG

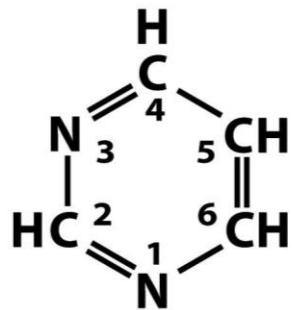
Protein

YGAX**V**LPMNGART

# Alineamiento de secuencias

Nucleic acids  
(5' -> 3')

A = Adenine  
C = Cytosine  
G = Guanine  
T = Thymine  
U = Uracyl



**Pyrimidine**

R = G A (puRine)

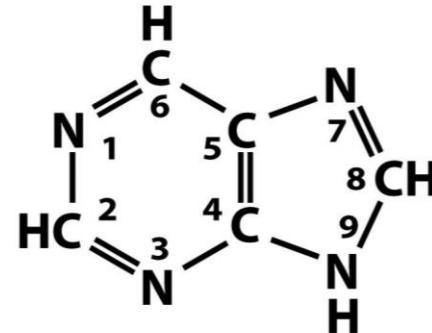
Y = T C (pYrimidine)

K = G T (Keto)

M = A C (aMino)

S = G C (Strong bonds)

W = A T (Weak bonds)



**Purine**

B = G T C (B is not A)

D = G A T (D is not C)

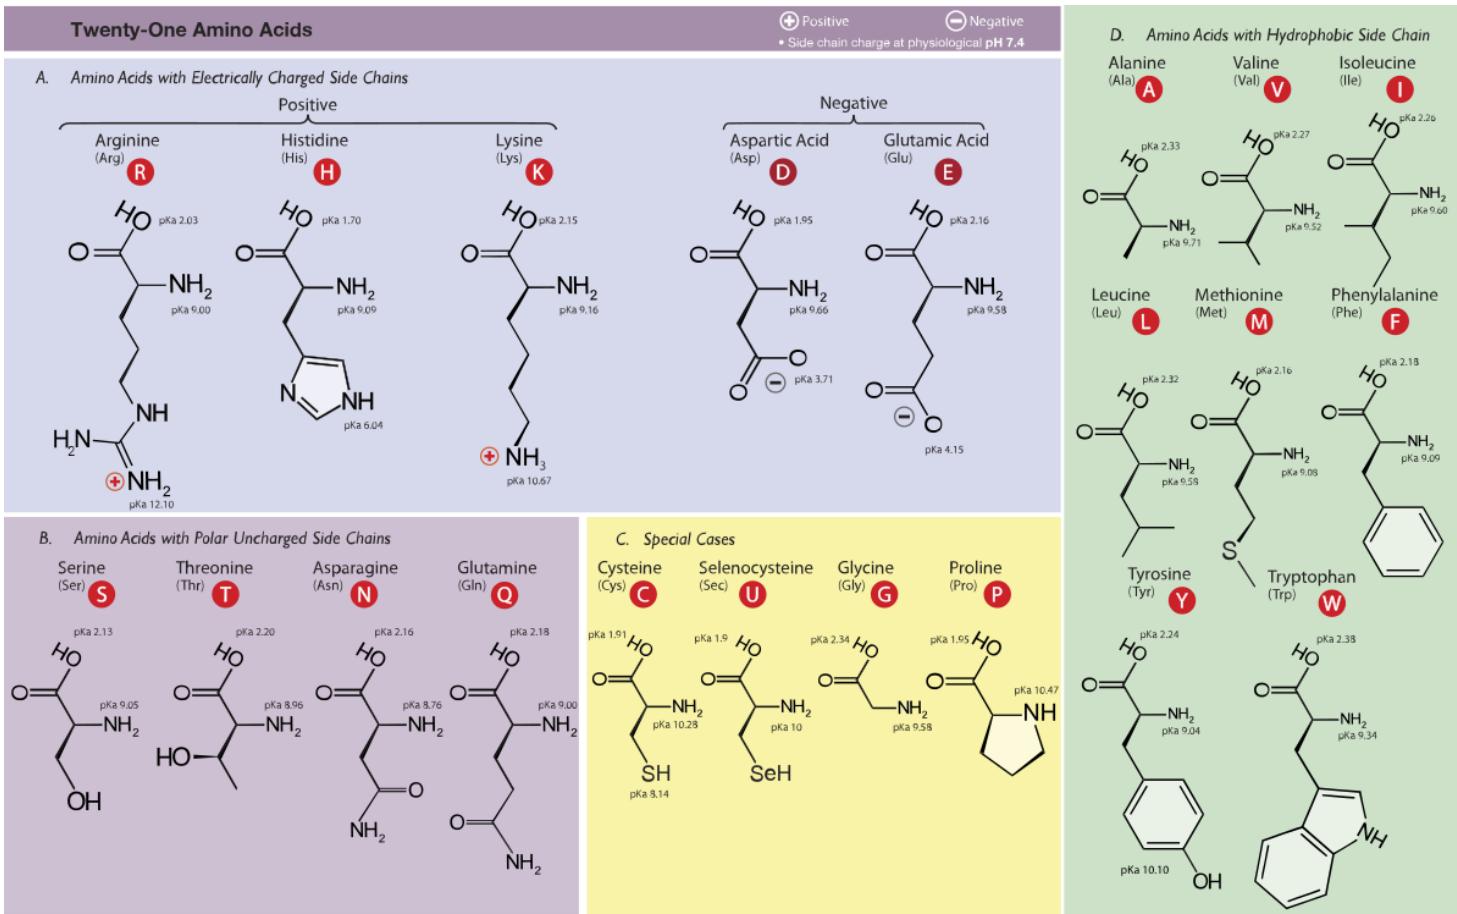
H = A C T (H is not G)

V = G C A (V is not T)

N = A G C T (aNy)

# Alineamiento de secuencias

## Proteins (N-terminus -> C-terminus)



# Alineamiento de secuencias

## Proteins

B: D/N

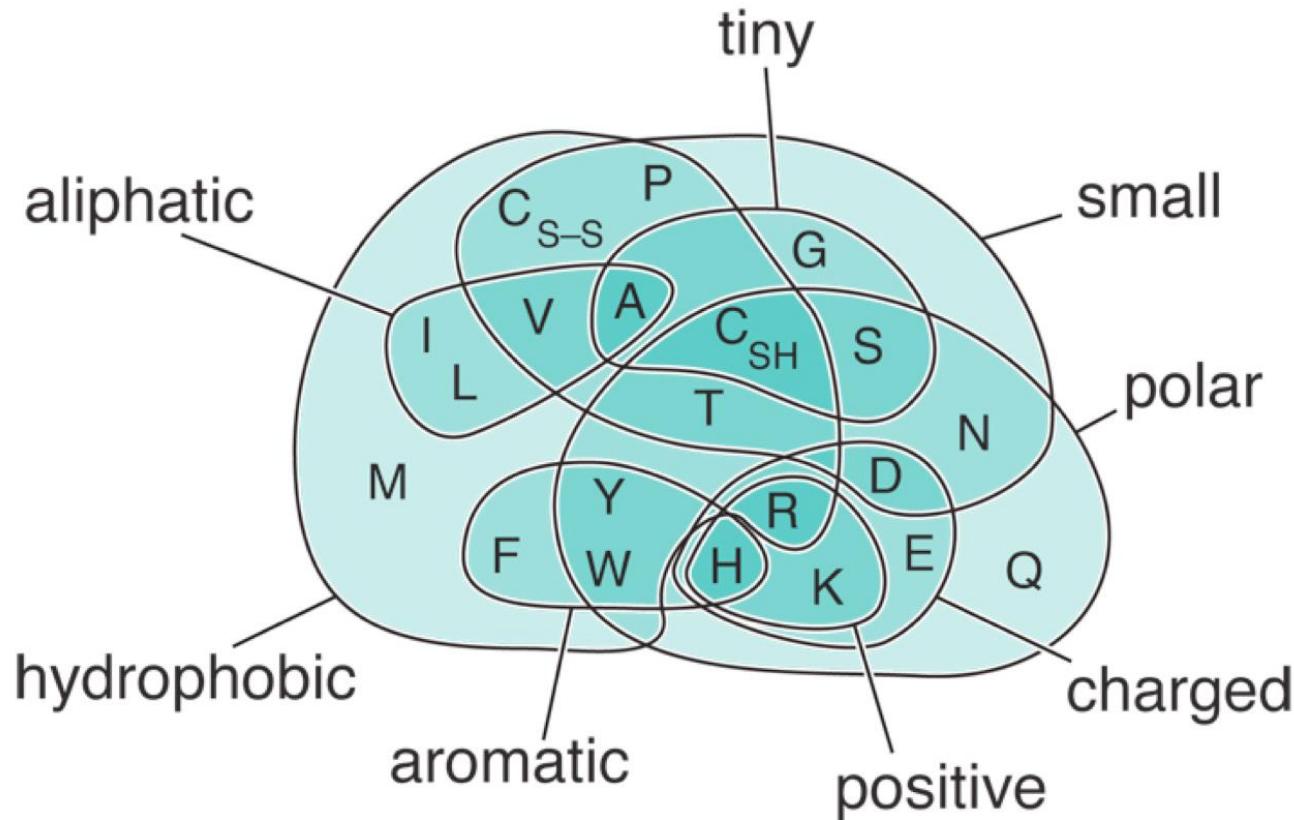
J: I/L

O: pyrrolysine

U: selenocysteine

X: unknown

Z: E/Q



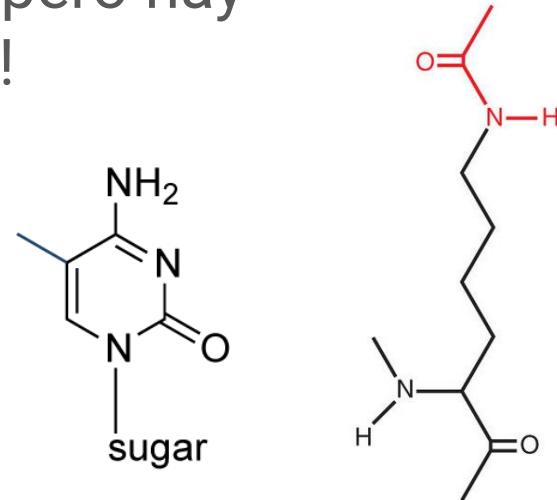
Propiedades fisicoquímicas importantes para identificar similitud

# Alineamiento de secuencias

La representación de biomoléculas en secuencias es fundamental para la bioinformática, pero hay **limitaciones que considerar!**

1. Ambigüedad de secuencias (N, X)
2. En general, no representan modificaciones (metilaciones, acetilaciones, etc..)
3. La secuencia no almacena la información de anotación

```
CDS
    /old_locus_tag="CTTA_0002"
    complement(1175..2188)
    /locus_tag="CTTA_RS00015"
    /old_locus_tag="CTTA_0002"
    /inference="COORDINATES: similar to AA
sequence:RefSeq:WP_012203330.1"
    /note="Derived by automated computational analysis using
gene prediction method: Protein Homology."
    /codon_start=1
    /transl_table=11
    /product="tripartite tricarboxylate transporter substrate
binding protein"
    /protein_id="WP_149354226.1"
```



5-methylcytosine  
(mC)

Acetyl-lysine

# Alineamiento de secuencias

---

## Convenciones generales de secuencias:

1. código de nucleótidos IUPAC;
2. código de aminoácidos IUPAC;
3. 5'- a 3'-, o N- a C-;
4. Para genomas, la dirección de la hebra debería estar en el sentido de la replicación (bacterias), o de acuerdo a su posición en el cromosoma (desde el telómero de brazo corto es 5'->)
5. Unidades: bp o pb (basepair o pares de bases), Kb ( $10^3$  bp), Mb ( $10^6$  bp), Gb ( $10^9$  bp).

# Alineamiento de secuencias

---

¿Qué es un alineamiento de secuencias y para qué sirve?

1. Comparación entre dos (o más) secuencias
2. Aproximación a homología de secuencias (ortólogos/paralogos)

¡Casi todos los análisis bioinformáticos son derivados de alguna manera desde inferencias basadas en homología de secuencias!

# Alineamiento de secuencias

## Homología vs Identidad vs Similitud

Dos genes son **homólogos** si divergieron de **un ancestro común**

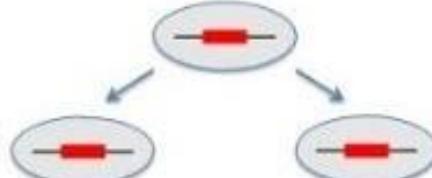
**Homología es una cualidad**

No existe algo altamente homólogo o 30% homólogo

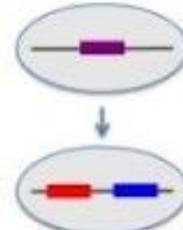


Dos genes **son o no son homólogos**, encontrando secuencias ortólogas o parólogas

Ortólogos



Parólogos



# Alineamiento de secuencias

## Homología vs Identidad vs Similitud

Dos genes son **homólogos** si divergieron de **un ancestro común**

Próteinas o genes homólogos, en general, tienen una estructura similar y usualmente poseen una función similar (hay que tener cuidado con esto)

Para identificar homología recurrimos a similitud de secuencias.

Parámetros de identidad (identity), similitud (similarity) y puntaje (scoring) mediante alineamiento de secuencias, además de otros parámetros!

(localización de residuos del sitio activo, estructura secundaria, patrones de residuos funcionales conservados, anotación de dominios proteicos)

# Alineamiento de secuencias

---

Teniendo lo anterior en consideración y entrando de lleno en alineamientos:

1. ¿Qué tipo de alineamiento es necesario? Pairwise? Local? Global? Multiple?
2. ¿Qué sistema de puntaje será usado (scoring)?
3. ¿Cúal algoritmo debo usar?
4. ¿Qué método estadístico será usado para evaluar la significancia de un alineamiento?

# Alineamiento de secuencias

## Pairwise sequence alignments (PSA)

$n = 2$

Q	K	E	S	G	P	S	S	S	Y	C	
V	Q	Q	E	S	G	L	V	R	T	T	C

## Multiple sequence alignments (MSA)

$n > 2$

Q	K	E	S	G	P	S	S	S	Y	C	
V	Q	Q	E	S	G	L	V	R	T	T	C
V	Q	K	E	S	L	L	V	R	S	T	C

BLAST  
EMBOSS (PSA)

MAFFT  
MUSCLE  
ClustalW  
Translator-X

# Alineamiento de secuencias

Cuando comparamos secuencias estamos buscando evidencia de que hayan divergido de un ancestro común. Para esto, se deben alinear las secuencias considerando los posibles modelos evolutivos que hayan causado su divergencia. En este proceso podemos encontrar **substitutiones, inserciones o delecciones (indels)**.

Un alineamiento es una forma de identificar regiones de similitud entre las secuencias.

**GFP**    **DGSVQLADHYQQNTPIGDGPVLLP**  
**RFP**    **DGGHYLVEFKSIY..MAKKPVQLP**

Pero, ¿cuál alineamiento

**GFP**    **DGSVQLADH....YQQNTPIGDGPVLLP**  
**RFP**    **DGGHYLVEFKSIY.....MAKKPVQLP**

es el correcto?

**GFP**    **DGSVQLADH...YQQNTPIGD.GPVLLP**  
**RFP**    **DGGHYLVEFKSIY.....MAKK.PVQLP**

# Alineamiento de secuencias

Para determinar cuales de los nucleótidos o residuos son causa de substitución o indels, se debe elegir una matriz de sustitución que permite dar un valor numérico al alineamiento.

**GFP**    DG**S**VQLADHYQQNTPIGDG**P**V**L**P  
**RFP**    DG**G**H**Y**LVEFKSIY..MAKK**P**V**Q**LP

Minimize gap length

**GFP**    DG**S**VQLADH....YQQNTPIGDG**P**V**L**P  
**RFP**    DG**G**H**Y**LVEFKSIY.....MAKK**P**V**Q**LP

Don't align non-equivalent residues

**GFP**    DG**S**VQLADH...YQQNTPIGD.**G**P**V**L**L**P  
**RFP**    DG**G**H**Y**LVEFKSIY.....MAKK.**P**V**Q**LP

Maximize similarity

En alineamientos de secuencias los indels son referidos como "*gaps*".

Definiendo dos eventos:  
"gap opening": aparición de un indel

"gap extension": extensión del indel en un carácter

# Alineamiento de Secuencias

## Matrices de substitución o puntuación

(Substitution or scoring matrices)

Estos definen la tasa de **substitución** de cada residuo en una secuencia a través del tiempo, entregando un valor numérico a cada mutación puntual definida.

BLOSUM62 matrix

Ala	4
Arg	-1 5
Asn	-2 0 6
Asp	-2 -2 1 6
Cys	0 -3 -3 -3 9
Gln	-1 1 0 0 -3 5
Glu	-1 0 0 2 -4 2 5
Gly	0 -2 0 -1 -3 -2 -2 6
His	-2 0 1 -1 -3 0 0 -2 8
Ile	-1 -3 -3 -3 -1 -3 -3 -4 -3 4
Leu	-1 -2 -3 -4 -1 -2 -3 -4 -3 2 4
Lys	-1 2 0 -1 -3 1 1 -2 -1 -3 -2 5
Met	-1 -1 -2 -3 -1 0 -2 -3 -2 1 2 -1 5
Phe	-2 -3 -3 -3 -2 -3 -3 -1 0 0 -3 0 6
Pro	-1 -2 -2 -1 -3 -1 -1 -2 -2 -3 -3 -1 -2 -4 7
Ser	1 -1 1 0 -1 0 0 0 -1 -2 -1 -1 4
Thr	0 -1 0 -1 -1 -1 -2 -2 -1 -1 -1 -2 -1 1 5
Trp	-3 -3 -4 -4 -2 -2 -3 -2 -2 -3 -2 -3 -1 1 -4 -3 -2 11
Tyr	-2 -2 -2 -3 -2 -1 -2 -3 2 -1 -1 -2 3 -3 -2 -2 2 7
Val	0 -3 -3 -3 -1 -2 -2 -3 -3 3 1 -2 1 -1 -2 -2 0 -3 -1 4

PAM250 matrix

C	12
S	0 2
T	-2 1 3
P	-3 1 0 6
A	-2 1 1 1 2
G	-3 1 0 -1 1 5
N	-4 1 0 -1 0 0 2
D	-5 0 0 -1 1 2 2 4
E	-5 0 0 -1 0 0 1 3 4
Q	-5 -1 -1 0 0 -1 1 2 2 4
H	-3 -1 -1 0 -1 -2 2 1 1 3 6
R	-4 0 -1 0 -2 -3 0 -1 -1 1 2 6
K	-5 0 0 -1 -1 -2 1 0 0 1 0 3 5
M	-5 -2 -1 -2 -1 -3 -2 -3 -2 -1 -2 0 0 6
I	-2 -1 0 -2 -1 -3 -2 -2 -2 -2 -2 2 5
L	-6 -3 -2 -3 -2 -4 -3 -4 -3 -2 -2 -3 -4 2 6
V	-2 -1 0 -1 0 -1 -2 -2 -2 -2 -2 -2 2 4 2 4
F	-4 -3 -3 -5 -4 -5 -4 -6 -5 -5 -2 -4 -5 0 1 2 -1 9
Y	0 -3 -3 -5 -3 -5 -2 -4 -4 -4 0 -4 -4 -2 -1 -1 -2 7 10
W	-8 -2 -5 -6 -6 -7 -4 -7 -7 -5 -3 2 -3 -4 -5 -2 -6 0 0 17
B	-4 0 0 -1 0 0 2 3 2 1 1 -1 1 -2 -2 -3 -2 -5 -3 -5 2
Z	-5 0 -1 0 0 -1 1 3 3 3 2 0 0 -2 -2 -3 -2 -5 -4 -6 2 3

C S T P A G N D E Q H R K M I L V F Y W B Z

# Alineamiento de Secuencias

## Algoritmos de alineamiento

Alineamiento global (global alignment)

Premisa: El puntaje total del alineamiento depende de la suma de todos los puntajes en pares de caracteres, menos una penalización por cada indel y su extensión

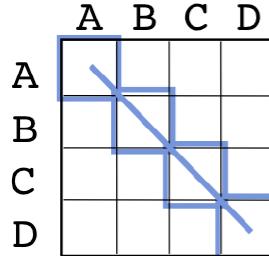
**El puntaje más alto posible es extendido  
en la mejor forma posible cada un  
residuo o nucleótido (caracteres)**

# Alineamiento de Secuencias

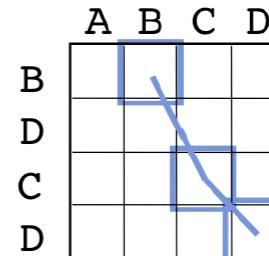
## Needleman-Wunsch algorithm (1970):

Cualquier alineamiento puede ser representado como un camino en una matriz que conecta cada intersección de columnas y filas de dos caracteres alineados

A   B   C   D  
A   B   C   D



A   B   -   C   D  
-   B   D   C   D



# Alineamiento de Secuencias

Needleman-Wunsch algorithm (1970):

El alineamiento óptimo esta dado por el camino que lleva a la suma más alta posible de todas las sumas de puntajes de a dos que contiene

First step: compile all pairwise scores into a matrix.

	A	B	C	D
B	0	<b>1</b>	0	0
D	0	0	0	<b>1</b>
C	0	0	<b>1</b>	0
D	0	0	0	<b>1</b>

# Alineamiento de Secuencias

## Needleman-Wunsch algorithm (1970):

El alineamiento óptimo esta dado por el camino que lleva a la suma más alta posible de todas las sumas de puntajes de a dos que contiene

Second step: The highest score in the last column and row is the highest pairscore we put there from the scoring matrix. This is the Base Case, if we think about the recursion, because there is no previous score we had to consider.

	A	B	C	D
B	0	<b>1</b>	0	0
D	0	0	0	<b>1</b>
C	0	0	<b>1</b>	0
D	0	0	0	<b>1</b>

# Alineamiento de Secuencias

## Needleman-Wunsch algorithm (1970):

El alineamiento óptimo esta dado por el camino que lleva a la suma más alta posible de todas las sumas de puntajes de a dos que contiene

Third step: Extend the path. Assign to each cell of the next column and row the highest value we can get by adding to its current value a value from a previous cell **that could be part of an alignment path.**

	A	B	C	D
B	0	1	0	0
D	0	0	0	1
C	0	0	1	0
D	0	0	0	1

	A	B	C	D
B	0	1	1	0
D	0	0	1	1
C	1	1	2	0
D	0	0	0	1

# Alineamiento de Secuencias

Needleman-Wunsch algorithm (1970):

El alineamiento óptimo esta dado por el camino que lleva a la suma más alta posible de todas las sumas de puntajes de a dos que contiene

	A	B	C	D
B	0	1	0	0
D	0	0	0	1
C	0	0	1	0
D	0	0	0	1

	A	B	C	D
B	0	1	1	0
D	0	0	1	1
C	1	1	2	0
D	0	0	0	1

	A	B	C	D
B	0	3	1	0
D	2	2	1	1
C	1	1	2	0
D	0	0	0	1

	A	B	C	D
B	2	3	1	0
D	2	2	1	1
C	1	1	2	0
D	0	0	0	1

A B - C D  
- B D C D

(This example assumes: identity matrix - match=1, mismatch=0, no gap penalties)